Mašinsko učenje 2026

Zadatak 1

Sadržaj

- Podsetnik - praktičan deo
- Zadatak 1
- SciPy Stack
- scikit-learn
- Uputstva i saveti

Podsetnik - praktičan deo

Podsetnik - praktičan deo

- Praktičan deo predmeta nosi najviše 60* bodova.
- Sastoji se od:
  - 3 domaća zadatka
  - Predmetnog projekta.
- Domaći zadaci se rade samostalno
- Projekat se može raditi timski (2-3 člana):
  - Svaki član tima mora dati svoj doprinos
  - Bodovi dodeljeni članovima istog tima mogu da se razlikuju.

* u posebnim slučajevima 60 bodova donosi i dodatnih 40.

Podsetnik - praktičan deo

- Bodovanje:
  - Svaki zadatak nosi najviše 20 bodova.
  - Projekat nosi najviše 20 bodova.
  - Predispitni bodovi sa domaćih zadataka i projekta ne mogu biti veći od 60.

Podsetnik - praktičan deo

- Domaći zadaci:
  - Testiranje modela na skrivenom test skupu podataka na *online* platformi.
  - Propratni izveštaj po unapred definisanom šablonu.
  - Zadatak je uspešno urađen ukoliko model ispuni zadati kriterijum.
  - Odbrana u terminima vežbi.
  - Broj bodova zavisi od ostvarenog rezultata, znanja i razumevanja prikazanog na odbrani.
  - Plagijat = diskvalifikacija!!!

Podsetnik - praktičan deo

- Raspored domaćih zadataka:
  - 30.03. - 27.04. Regresija
    - Predstavljanje na vežbama: 30.03. - 02.04.
    - Odbrana na vežbama: 04.05. - 08.05.
  - 04.05. - 20.05. Klasifikacija
    - Predstavljanje na vežbama: 04.05. - 08.05.
    - Odbrana na vežbama: 25.05. - 29.05.
  - 25.05. - 10.06. Klasterovanje
    - Predstavljanje na vežbama: 25.05. - 29.05.
    - Odbrana na vežbama: 15.06. - 19.06.

Zadatak 1

Zadatak 1

- Višestruka regresija:
  - Prediktovati cenu (kolona **Cena** u **evrima**) stanova u Srbiji na osnovu više atributa.
  - Zadatak je uspešno urađen ukoliko se na kompletnom testnom skupu podataka dobije **MAPE (Mean Absolute Percentage Error) manji od 0.3 (30%)**.
  - Rok za izradu zadatka je **27.04.2026. u 23:59h**.

Zadatak 1

- Atributi (kolone) na osnovu kojih se prediktuje cena:
  - **Slike** - broj fotografija stana
  - **Naziv** - ime stana. Može biti ime dela grada, ulice, stambenog kompleksa…
  - **Grad** - mesto gde se stan nalazi:
    - **Beograd, Novi Sad, Niš, Kruševac, Subotica**
  - **Kvadratura** - površina stana u m^2
  - **Sobe** - broj soba u stanu
  - **Sprat** - sprat na kom se stan nalazi. Pored numeričkih vrednosti sadrži i:
    - **prizemlje, suteren, nisko prizemlje, potkrovlje**
  - **Prodavac** - ko prodaje stan:
    - **Agencija, Vlasnik, Investitor**

Zadatak 1

- Atributi (kolone) na osnovu kojih se prediktuje cena:
  - **Uknjizen** - da li je stan uknjižen:
    - **Da, Ne**
  - **Garaza** - da li uz stan ide i garaža:
    - **Da, Ne**
  - **Parking** - da li uz stan ide parking mesto:
    - **Da, Ne**

Zadatak 1

- Gradivo za Zadatak 1 obuhvata kompletno gradivo od početka semestra zaključno sa **Metodom maksimalne verodostojnosti**.
- Koncepti vezani za Zadatak 1 (podsetiti se gradiva sa predavanja i ranijih predmeta) (1/2):
  - Jednostruka linearna regresija
  - Normalizacija
  - *Outlier*-i
  - Rad sa skupom podataka
  - Pravilno računanje metrike

Zadatak 1

- Koncepti vezani za Zadatak 1 (podsetiti se gradiva sa predavanja i ranijih predmeta) (2/2):
  - Rad sa kategoričkim podacima
  - Matrica korelacije
  - Višestruka linearna regresija
  - Regularizacija
  - Neparametarski pristup.

Zadatak 1

- Jednostruka linearna regresija:
  - *y = h(x)*

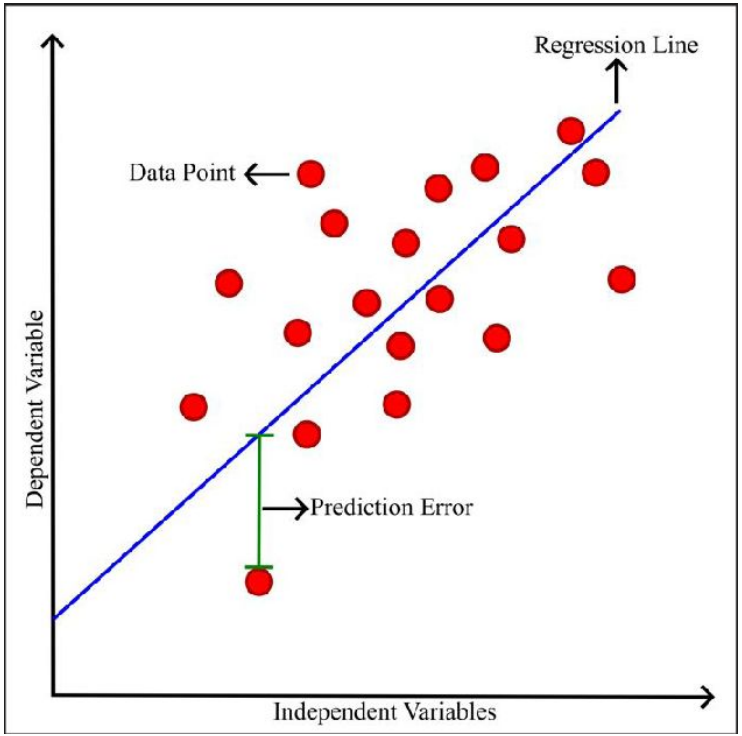

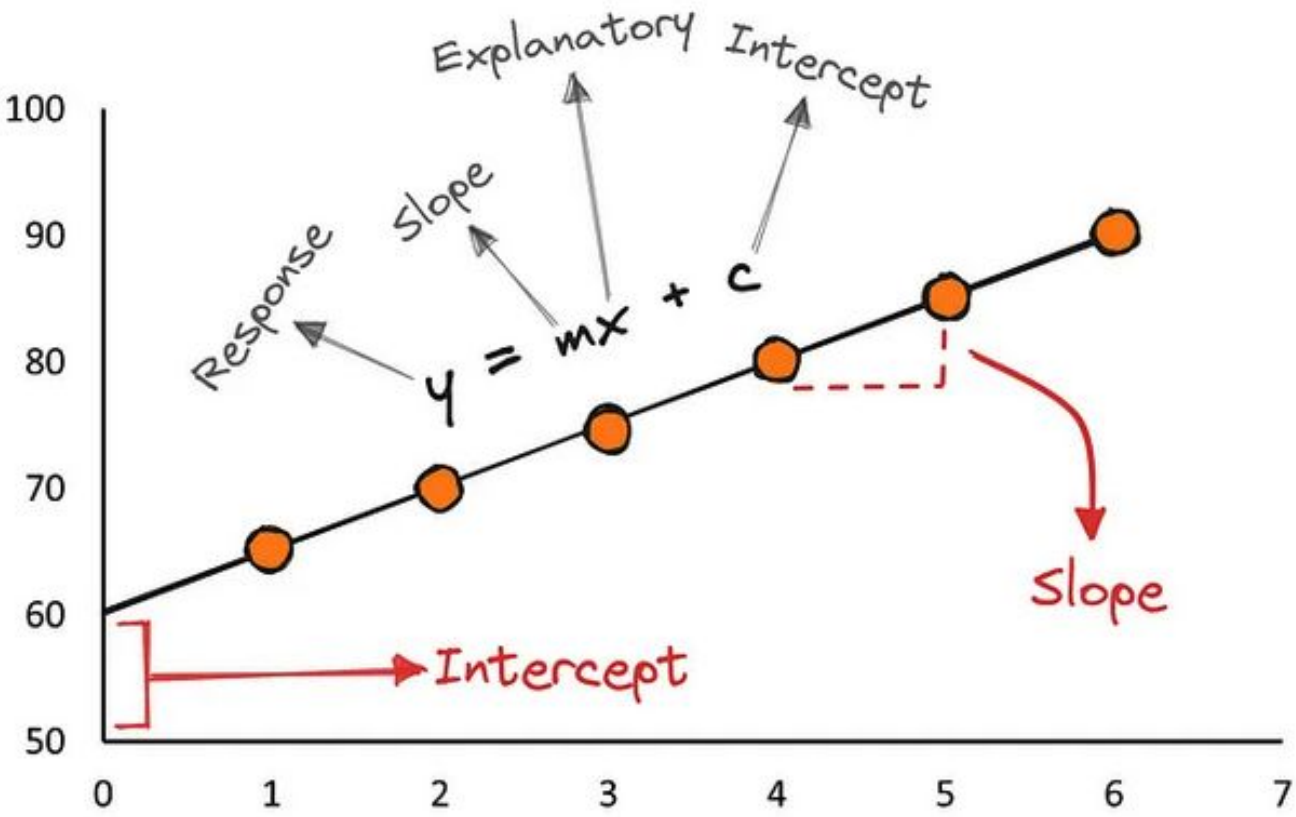
Explanatory
Intercept
Slope
Response
y = mx + c
Slope
Intercept
100
90
80
70
60
50
0
1
2
3
4
5
6
7

Zadatak 1

- Normalizacija:
  - *min-max* normalizacija:
    - *normalized_data = (data - np.min(data)) / (np.max(data) - np.min(data))*
  - *z-score* normalizacija:
    - *normalized_data = (data - np.mean(data)) / np.std(data)*
  - **Koeficijenti se računaju isključivo na trening skupu podataka, a koriste se za normalizaciju i trening i testnog skupa podataka**

Zadatak 1

- *Outlier*-i:
  - Podaci koji se značajno razlikuju od ostalih opažanja:
    - Greške u merenju, greške u unosu podataka, neobični opaženi fenomeni,...
  - Mogu imati veliki uticaj na rezultujući model
  - Neke od strategija za rad sa *outlier*-ima:
    - Ignorisanje
      - Ako imaju minimalan uticaj na performanse modela
    - Uklanjanje
      - Ručno
      - Korišćenjem neke od statističkih metoda:
        - *z-score*: udaljenost opservacije od srednje vrednosti izražena u broju standardnih devijacija
      - **Na ovom kursu je dozvoljeno uklanjanje:**
        - **Redova i kolona iz trening skupa podataka**
        - **Kolona iz test skupa podataka**

Zadatak 1

- *Outlier*-i:
  - Neke od strategija za rad sa *outlier*-ima:
    - Transformacija podataka
      - Npr.: logaritamska transformacija
        - *transformed_data = np.log(data)*
    - Korišćenje robusnih metoda:
      - Koristiti algoritme koji su prirodno otporni(ji) na *outlier*-e.

Zadatak 1

- Rad sa skupom podataka:

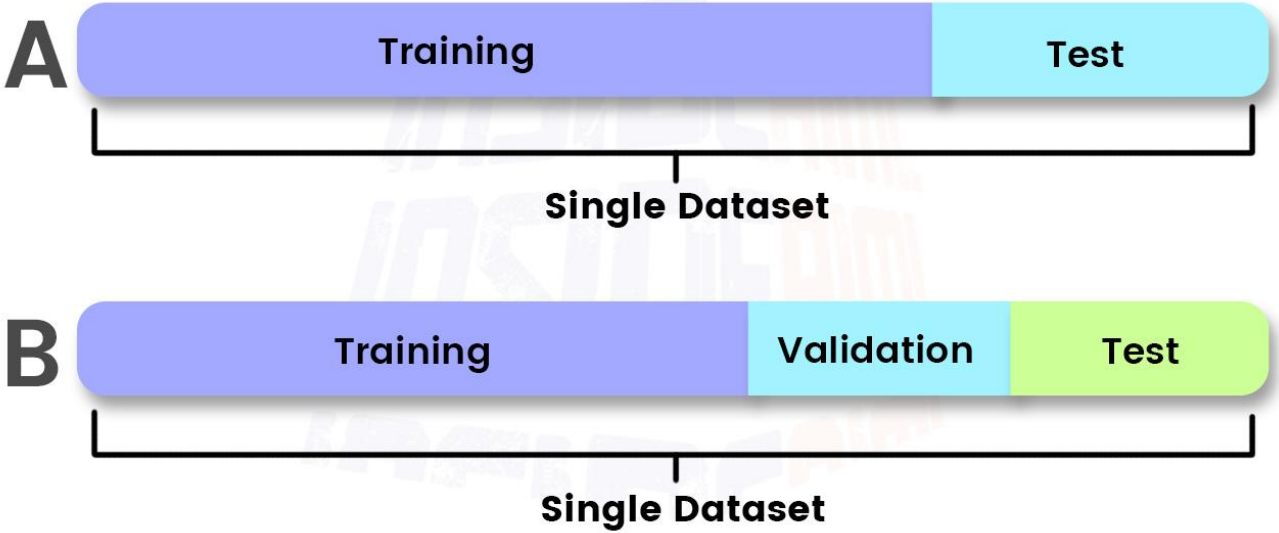

Zadatak 1

- Rad sa skupom podataka:

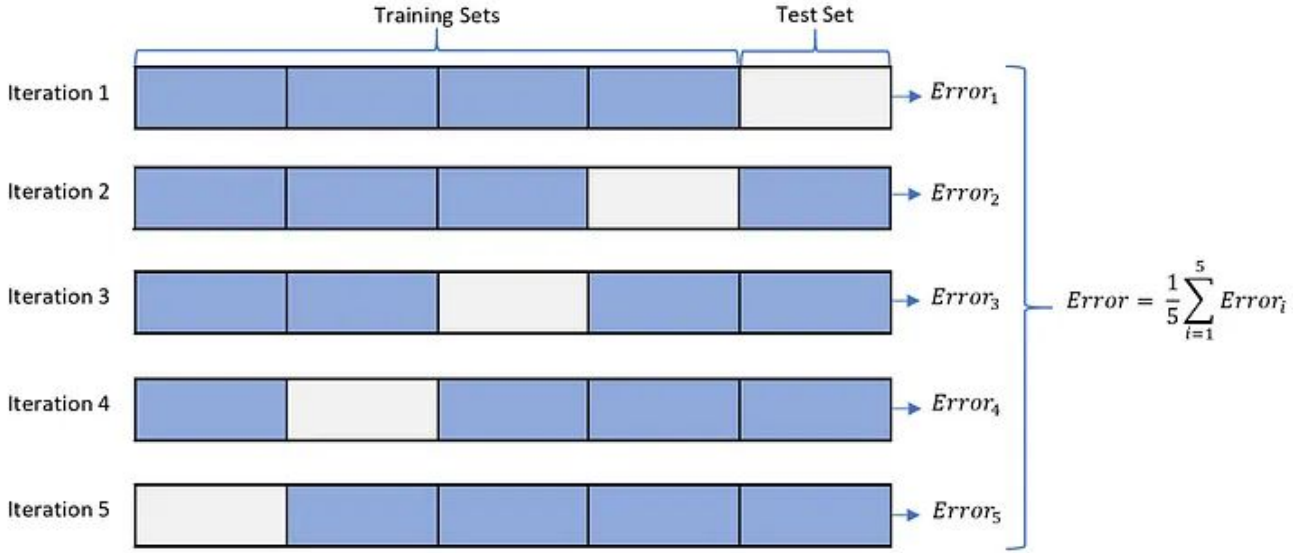

Zadatak 1

- Pravilno računanje metrike:
  - A_t - stvarna vrednost
  - F_t - predviđena vrednost

$$\mathrm{MAPE} = 100 \frac{1}{n} \sum_{t=1}^{n} \left| \frac{A_t - F_t}{A_t} \right|$$

Zadatak 1

- Pravilno računanje metrike:
  - Ako su podaci prethodno bili transformisani, potrebno ih je vratiti u originalan oblik pre računanja metrike
  - Na primer, ako su podaci normalizovani, pre računanja metrike ih je potrebno denormalizovati:
    - *min-max* denormalizacija:
      - `data = normalized_data * (np.max(data) - np.min(data)) + np.min(data)`
    - *z-score* denormalizacija:
      - `data = normalized_data * np.std(data) + np.mean(data)`

Zadatak 1

- Rad sa kategoričkim podacima:
  - Atributi (kolone) **Naziv**, **Grad**, **Sprat**, **Prodavac, Uknjizen, Garaza** i **Parking** sadrže kategoričke podatke.
  - Neke od tehnika za rad sa kategoričkim podacima su:
    - **Label Encoding** - konvertovanje kategoričkih podataka u broj iz opsega [0, broj-klasa-1], npr.: za kolonu **Uknjizen** vrednosti **[Da, Ne]** će se konvertovati u vrednosti **[0, 1]**.
    - **One Hot Encoding** - konvertovanje svake klase u novu kolonu i pridruživanje vrednosti 1 ili 0 (*True* ili *False*), npr.: za kolonu **Uknjizen** ćemo dobiti dve binarne kolone **Uknjizen_Da** i **Uknjizen_Ne**.
    - **Custom Binary Encoding** - kombinacija **Label Encoding**-a i **One Hot Encoding**-a kako bi se kreirala dodatna kolona od značaja.

Zadatak 1

- Matrica korelacije:
  - Svaki element u matrici pokazuje koeficijent korelacije između 2 promenljive iz opsega **[-1, 1]** gde:
    - **1** označava savršenu pozitivnu korelaciju (kako jedna promenljiva raste, tako raste i druga)
    - **0** označava da nema korelacije
    - **-1** označava savršenu negativnu korelaciju (kako jedna promenljiva raste, druga opada).
  - Razumevanje matrice korelacije može pomoći u:
    - Izboru promenljivih za modele
    - Otkrivanju mogućih uzročno-posledičnih veza
    - Izbegavanju problema multikolinearnosti.

Zadatak 1

- Matrica korelacije:
  - *NumPy*:
    - *correlation_matrix = np.corrcoef(data)*
  - *Pandas*:
    - *correlation_matrix = df.corr()*

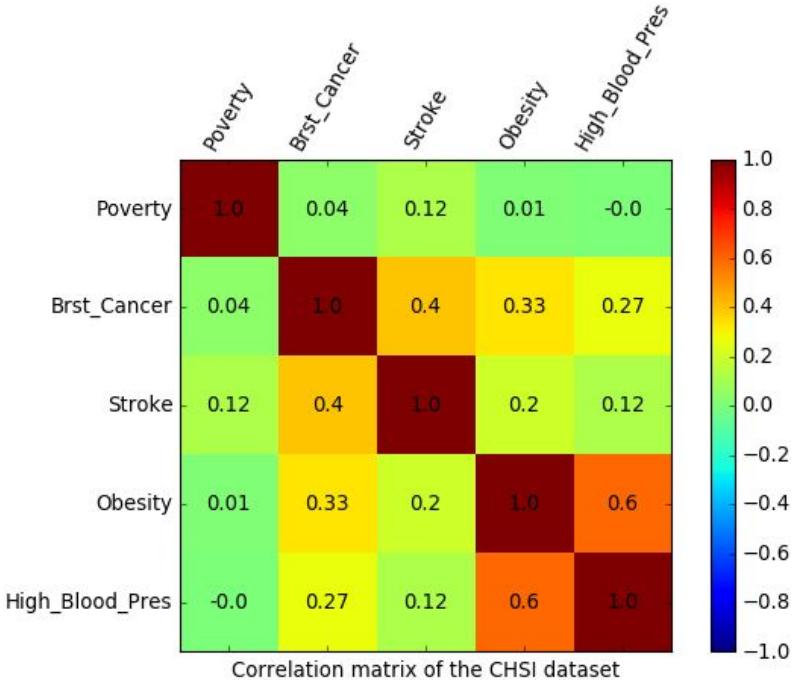

Zadatak 1

- Višestruka linearna regresija:
  - *y = h(x1, x2, x3…)*

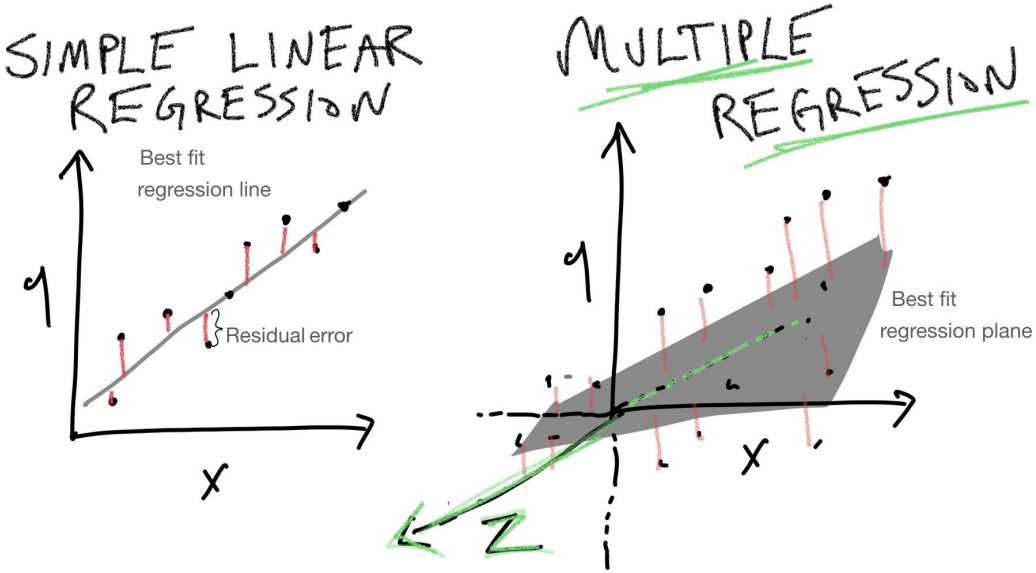

Zadatak 1

- Regularizacija:
  - Modifikacija optimizacionog problema koje ograničava prilagodljivost modela i čini ga manje podložnim preprilagođavanju
  - *Lasso* (L1):
    - *Gradient Descent*
    - *Coordinate Descent*
  - *Ridge* (L2):
    - *Gradient Descent*
    - *Closed Form Solution*
  - *Elastic Net:*
    - Linearna kombinacija L1 i L2

Zadatak 1

- Neparametarski pristup:
  - Jednostavnost i fleksibilnost
  - *Nearest Neighbors*
  - *Kernel Regression*

SciPy Stack

Zadatak 1

- Za izradu zadataka koristiti **Python 3.12**.
- Preporuka da se prilikom izrade zadataka oslonac bude SciPy Stack i njegove biblioteke:
  - NumPy
  - SciPy
  - Matplotlib
  - Jupyter
  - Pandas.

Zadatak 1

- Za Zadatak 1 na platformi su instalirane biblioteke (verzije date u Uputstvu):
  - **NumPy:**
    - Docs
    - Stanford Tutorial
  - **Pandas:**
    - Docs
    - Tutorial
    - 10 Minutes to Pandas.
- Za potrebe vizualizacije podataka i pisanja propratnog izveštaja od pomoći može biti biblioteka **Matplotlib**:
  - Docs
  - Tutorial.

scikit-learn

Zadatak 1

- **scikit-learn** biblioteka:
  - Instalacija
  - Docs.
- Izdvojeno:
  - Selekcija modela
  - Preprocesiranje i normalizacija
  - Metrike
  - Linearni modeli.

Uputstva i saveti

Zadatak 1

- Uputstvo za rad sa platformom i pisanje propratnog izveštaja se nalazi u:
  - **Files/Vežbe/Uputstvo.pdf**.
- Saveti za rešavanje zadataka:
  - Podsetiti se gradiva sa predavanja
  - Detaljno pročitati uputstvo za rad sa platformom i pisanje propratnog izveštaja
  - Vizualizovati i analizirati podatke
  - Pokušati smanjiti dimenzionalnost problema
  - Isprobati i parametarske i neparametarske pristupe
  - Ako se radi normalizacija podataka, obratiti pažnju kako će se računati metrika.

Zadatak 1

- Dodatno istraživanje:
  - Gradivo obrađeno na predavanjima i vežbama je dovoljno kako bi se zadatak uspešno uradio
  - Dodatnim istraživanjem (pod)oblasti i problema moguće je ostvariti bolje rezultate.
  - Ohrabruje se dodatno istraživanje i primena istraženog, uz (jedino) ograničenje da (novi, istraženi) algoritmi moraju biti algoritmi regresije
  - Ne postoje ograničenja što se tiče tehnika za obradu podataka i rad sa trening skupom
  - Pošaljite asistentu e-mail ukoliko niste sigurni da li nešto sme ili ne sme da se iskoristi za izradu zadatka.